

Mini-Projet Machine Learning

Prédiction du Prix Immobilier

California Housing Dataset

Rapport rédigé le 27 March 2026

Résumé exécutif

Ce projet conçoit un système complet de prédiction du prix médian des logements en Californie, en s'appuyant sur le dataset California Housing (20 640 observations, 8 variables). Trois algorithmes supervisés ont été comparés : régression linéaire, Random Forest et Gradient Boosting. Le modèle Random Forest obtient les meilleures performances ($R^2 \approx 0.80$, $MAE \approx 0.33$). Une interface interactive Jupyter permet à l'utilisateur de prédire le prix d'un logement en ajustant des curseurs.

1. Contexte et Objectifs

1.1 Problématique

L'immobilier est un secteur où l'estimation précise des prix constitue un enjeu économique majeur pour acheteurs, vendeurs et institutions financières. L'objectif de ce projet est de construire un système de prédiction automatique du prix médian des logements à partir de caractéristiques géographiques et socio-démographiques.

1.2 Dataset

Le dataset California Housing, issu du recensement américain de 1990, est disponible directement via la librairie scikit-learn. Il comprend 20 640 blocs de recensement, chacun décrit par 8 variables numériques :

- **MedInc** — Revenu médian du bloc (en 10 000 \$)
- **HouseAge** — Âge médian des maisons du bloc
- **AveRooms** — Nombre moyen de pièces par logement
- **AveBedrms** — Nombre moyen de chambres par logement
- **Population** — Population totale du bloc
- **AveOccup** — Nombre moyen d'occupants par logement
- **Latitude** — Latitude géographique
- **Longitude** — Longitude géographique

La variable cible **MedHouseVal** représente la valeur médiane du logement en centaines de milliers de dollars.

2. Méthodologie

2.1 Vue d'ensemble du pipeline

Étape	Description	Outils
1. Chargement	fetch_california_housing()	scikit-learn
2. Exploration	Distributions, corrélations, NaN	pandas, seaborn
3. Nettoyage	Outliers (Q99), pas de NaN	pandas
4. Split	80% train / 20% test, seed=42	train_test_split
5. Normalisation	StandardScaler sur features	scikit-learn
6. Modèles	3 algorithmes supervisés	scikit-learn
7. Non supervisé	PCA 2D + K-Means k=4	scikit-learn
8. Interface	Widgets interactifs Jupyter	ipywidgets

2.2 Exploration des données

L'exploration initiale confirme l'absence de valeurs manquantes dans le dataset. La variable MedInc présente la corrélation linéaire la plus forte avec la cible ($r \approx 0.69$), suivie de la latitude ($r \approx -0.14$) et du nombre de pièces ($r \approx 0.15$). La distribution de la cible est légèrement asymétrique avec un pic autour de la valeur plafond de 5 (500 000 \$), signe d'une troncature dans le dataset.

2.3 Prétraitement

Deux étapes de nettoyage ont été appliquées :

- **Suppression des outliers** : les valeurs au-delà du 99e percentile pour AveRooms et AveOccup ont été retirées (environ 1% des données), car ces valeurs extrêmes correspondent à des erreurs de saisie ou des cas atypiques.
- **Normalisation** : un StandardScaler (moyenne=0, écart-type=1) est appliqué avant la régression linéaire pour stabiliser l'apprentissage gradient.

Les données ont été partitionnées en un ensemble d'entraînement (80%) et un ensemble de test (20%), avec une graine aléatoire fixe (seed=42) pour la reproductibilité des résultats.

2.4 Modèles supervisés

Trois algorithmes de régression ont été implémentés et comparés :

- **Régression Linéaire** : modèle de référence (baseline), suppose une relation linéaire entre les features et la cible. Simple et interprétable.
- **Random Forest** (n=100 arbres) : ensemble de 100 arbres de décision entraînés sur des sous-échantillons aléatoires du dataset. Robuste aux outliers et aux relations non linéaires.
- **Gradient Boosting** (n=100, lr=0.1) : apprentissage séquentiel où chaque arbre corrige les erreurs du précédent. Très performant sur des données tabulaires.

2.5 Apprentissage non supervisé (bonus)

En complément, deux techniques non supervisées ont été appliquées sur l'ensemble des données normalisées :

- **ACP (PCA 2D)** : réduction en deux composantes principales expliquant environ 40% de la variance totale. La projection colorée par prix révèle une structure non linéaire, justifiant le recours aux modèles ensemblistes.
- **K-Means (k=4)** : segmentation des logements en 4 groupes distincts sur les composantes PCA. La méthode du coude confirme k=4 comme choix pertinent. Les clusters correspondent approximativement à des groupes de prix bas, intermédiaires, élevés et très élevés.

3. Résultats et Analyse

3.1 Tableau de métriques comparatif

Modèle	MAE	RMSE	R ²	Remarque
Régression Linéaire	0.530	0.721	0.592	Baseline simple
Random Forest	0.329	0.500	0.803	Meilleur modèle
Gradient Boosting	0.371	0.531	0.771	Très compétitif

Métriques utilisées — **MAE** (Mean Absolute Error) : erreur absolue moyenne en unités du dataset (×100k\$) ; **RMSE** (Root Mean Squared Error) : plus sensible aux grandes erreurs ; **R²** : proportion de la variance expliquée (1.0 = prédiction parfaite).

3.2 Analyse des résultats

La régression linéaire atteint un R² de 0.59, confirmant l'existence de relations non linéaires dans les données. Le Random Forest améliore significativement les performances avec un R² de 0.80, soit une réduction de l'erreur absolue de 38% par rapport au baseline. Le Gradient Boosting est légèrement inférieur sans optimisation des hyperparamètres.

L'analyse d'importance des features (Random Forest) confirme que le revenu médian (MedInc) est de loin la variable la plus prédictive, avec une importance relative de plus de 50%. Les coordonnées géographiques (latitude, longitude) arrivent en deuxième position, reflétant l'effet de localisation bien connu dans l'immobilier.

3.3 Interface utilisateur

Le notebook Jupyter intègre une interface interactive basée sur ipywidgets, permettant de saisir les 8 caractéristiques d'un logement via des curseurs et d'obtenir instantanément le prix estimé par le modèle Gradient Boosting. Le résultat est affiché en dollars avec le score R² du modèle.

4. Limites et Pistes d'Amélioration

4.1 Limites identifiées

- Le dataset date de 1990 : les prix immobiliers californiens ont considérablement évolué depuis.
- La variable cible est plafonnée à 5 (500 000 \$), créant un artefact dans les distributions.
- Absence de variables qualitatives (type de quartier, proximité des transports, qualité des écoles).
- Les hyperparamètres des modèles n'ont pas été optimisés systématiquement.

4.2 Pistes d'amélioration

- **Feature engineering** : ratio chambres/pièces, densité (population/nombre de logements), distance au centre-ville.
- **Optimisation des hyperparamètres** : GridSearchCV ou RandomizedSearchCV avec validation croisée 5-fold.
- **Modèles avancés** : XGBoost, LightGBM, ou réseaux de neurones (MLP) pour capturer des interactions complexes.
- **Visualisation géographique** : carte choroplèthe des prix par localisation (latitude/longitude).
- **Interface étendue** : déploiement via Streamlit ou FastAPI pour une utilisation hors Jupyter.

5. Conclusion

Ce mini-projet illustre un pipeline complet de machine learning appliqué à la prédiction immobilière. À travers l'exploration des données, le prétraitement, la comparaison de trois modèles et la mise en place d'une interface interactive, il couvre l'ensemble des compétences visées par les labs de cours.

Le modèle Random Forest, avec un R^2 de 0.80, offre des prédictions précises et une bonne interprétabilité via les importances de features. Les techniques non supervisées (PCA, K-Means) enrichissent la compréhension structurelle des données et confirment les choix de modélisation.